



Universidade de Brasília
Departamento de Estatística

Modelo GAMLSS para Análise e Previsão da Taxa de Desemprego

Mateus Vieira Costa

Pré-projeto de pesquisa para disciplina de
Tópicos em estatística 2 do Departamento
de estatística da Universidade de Brasília.

Brasília
2025

Mateus Vieira Costa

Modelo GAMLSS para Análise e Previsão da Taxa de Desemprego

Pré-projeto de pesquisa para disciplina de
Tópicos em estatística 2 do Departamento
de estatística da Universidade de Brasília.

**Brasília
2025**

Sumário

1 Introdução	4
2 Metodologia	7
2.1 Especificação do Modelo	7
2.2 Distribuição Utilizada	7
2.3 Estimação dos Parâmetros	8
2.4 Ferramentas Computacionais	8
2.5 Covariáveis Consideradas	8
2.6 Critérios de Avaliação do Modelo.	8
2.7 Análise descritiva.	9
2.7.1 Idade	9
2.7.2 Gênero	11
2.7.3 Etnia	12
2.7.4 Grau de instrução	13
2.7.5 Tipo área	14
2.8 Unidade Federativa.	15
3 Modelo e resultados parciais	16

1 Introdução

A análise de indicadores socioeconômicos, como renda per capita, desempenho educacional e índices de pobreza, é essencial para o desenvolvimento de políticas públicas (HOFFMANN, 2016). Esses indicadores muitas vezes apresentam características como assimetria, heterocedasticidade e caudas longas, que não são adequadamente modeladas por abordagens tradicionais, como a regressão linear ou modelos lineares generalizados (MLGs) (BOURGUIGNON, 2000).

A taxa de desemprego é um dos principais indicadores utilizados para medir desigualdade, pobreza e condições socioeconômicas (MILANOVIC, 2016). A taxa de desemprego, definida como a razão entre o número de pessoas desocupadas e a força de trabalho, apresenta desafios para modelagem estatística devido à sua natureza assimétrica, heterocedástica e assimétrica, possível superdispersão e variação ao longo do tempo e entre diferentes regiões. Além disso, fatores socioeconômicos e demográficos influenciam sua distribuição, tornando essencial a escolha de modelos que acomodem essas características, como abordagens baseadas em distribuições flexíveis e modelagem hierárquica. Tais propriedades dificultam o uso de métodos tradicionais, como regressão linear ou MLGs, que frequentemente assumem normalidade ou distribuições inadequadas para esses dados.

Os Modelos de Local, Escala e Forma Generalizados (GAMLSS), desenvolvidos por Rigby & Stasinopoulos (2005), oferecem maior flexibilidade ao permitir o uso de distribuições assimétricas e personalizáveis. Esses modelos possibilitam que parâmetros além da média (como dispersão, assimetria e curtose) sejam influenciados por covariáveis, o que os torna ideais para dados socioeconômicos complexos (STASINOPOULOS, 2017).

Modelos lineares generalizados frequentemente assumem distribuições inadequadas para indicadores com assimetria e alta variabilidade, no caso específico do desemprego, acaba negligenciando aspectos como heterogeneidade e assimetria. Qual é o impacto da aplicação de GAMLSS no ajuste de dados socioeconômicos em relação às abordagens tradicionais? Como os modelos GAMLSS podem melhorar o ajuste e a predição da taxa de desemprego em comparação a modelos mais simples?

Os modelos GAMLSS têm um impacto significativo no ajuste e na predição de dados socioeconômicos devido à sua flexibilidade em capturar as características complexas desses dados (SILVA, 2013). Comparados às abordagens tradicionais, como regressões lineares ou MLGs, os GAMLSS oferecem vantagens substanciais.

A taxa de desemprego frequentemente apresenta assimetria positiva, com a maioria das regiões exibindo valores relativamente baixos e algumas enfrentando níveis significativamente elevados. Além disso, sua distribuição pode apresentar caudas pesadas, refletindo a existência de áreas com taxas de desemprego excepcionalmente altas. Os

modelos GAMLSS permitem a escolha de distribuições flexíveis, como Beta Inflacionada e Pareto Generalizada, que melhor capturam essas características. Isso possibilita um ajuste mais preciso do modelo, especialmente em cenários onde abordagens tradicionais, que assumem normalidade ou transformações simples, não conseguem representar adequadamente a variabilidade dos dados (STASINOPOULOS, 2005).

A variabilidade em dados socioeconômicos não é constante (CRIBARI-NETO, 2004); por exemplo, a dispersão da taxa de desemprego pode ser maior em certas regiões ou grupos populacionais. Os GAMLSS permitem modelar explicitamente a variabilidade (σ) como função de covariáveis, algo que os MLGs tradicionais não conseguem fazer. Ou seja, os GAMLSS possuem capacidade de descrever e entender melhor as diferenças na dispersão entre subgrupos populacionais.

Além de média (μ) e variabilidade (σ), os GAMLSS permitem modelar diretamente a assimetria (ν) e a curtose (τ) (BASTIANI, 2017). Isso é crucial para dados socioeconômicos, nos quais assimetrias e valores extremos carregam informações importantes. Com isso os modelos mais completos que capturam nuances adicionais da distribuição (SILVA, 2013).

Dados socioeconômicos frequentemente possuem censura ou truncamento, como rendas declaradas abaixo de um certo limite (ex.: "renda menor que R\$ 1.500"). Os GAMLSS suporta distribuições que lidam diretamente com essas características, consequentemente evita vieses que surgem quando se ignora a censura/truncamento (MILANOVIC, 2016).

Nos GAMLSS, todos os parâmetros (μ , σ , ν , τ) podem ser modelados como funções das covariáveis. Isso permite uma análise mais rica e detalhada do impacto de fatores explicativos, como escolaridade, região, ou idade (STASINOPOULOS, 2005).

Os GAMLSS permitem melhor ajuste estatístico, já que a possibilidade de testar múltiplas distribuições permite identificar aquela que melhor representa os dados, critérios de seleção de modelos, como o AIC e o BIC, geralmente mostram que os GAMLSS oferecem melhor ajuste em comparação com MLGs (BASTIANI, 2017). Geralmente têm previsões mais precisas, modelos tradicionais, ao ignorarem a variabilidade heterogênea ou a forma completa da distribuição, podem produzir previsões enviesadas ou imprecisas, já os GAMLSS, ao capturarem padrões mais detalhados da distribuição, resultam em previsões mais robustas e acuradas (SILVA, 2013).

Os GAMLSS também permitem modelar padrões específicos para diferentes subgrupos populacionais, como regiões, níveis de escolaridade ou categorias de emprego, isso é particularmente útil para prever o desemprego em contextos regionais ou em grupos minoritários, onde os padrões diferem substancialmente (HOFFMANN, 2016).

Em resumo, Os GAMLSS oferecem uma solução avançada para capturar a com-

plexidade de dados socioeconômicos como a taxa de desemprego. Com maior flexibilidade e capacidade de modelar parâmetros adicionais da distribuição. Com isto os objetivos dessa pesquisa são:

- Analisar e prever a taxa de desemprego no Brasil utilizando modelos GAMLSS.
- Investigar como fatores socioeconômicos influenciam diferentes aspectos da distribuição da taxa de desemprego (média, variabilidade, assimetria e curtose).

Compreender os fatores que afetam o desemprego é essencial para subsidiar políticas públicas voltadas à redução da desigualdade. O uso de modelos GAMLSS oferece uma abordagem metodológica avançada que pode revelar informações mais detalhadas sobre a distribuição do desemprego.

2 Metodologia

Neste estudo, utilizaremos os GAMLSS para modelar e prever a taxa de desemprego. Essa abordagem nos permite modelar a média (μ), dispersão (σ), assimetria (ν) e curtose (τ) de forma flexível, considerando distribuições apropriadas para os dados socioeconômicos, que frequentemente apresentam assimetria e caudas pesadas.

2.1 Especificação do Modelo

A variável resposta Y , representando a taxa de desemprego, é modelada como uma variável aleatória seguindo uma distribuição $D(\mu, \sigma, \nu, \tau)$, onde:

$$Y \sim D(\mu, \sigma, \nu, \tau),$$

com os parâmetros definidos como funções das covariáveis:

$$\begin{aligned} g_\mu(\mu) &= \mathbf{X}_\mu \boldsymbol{\beta}_\mu, \\ g_\sigma(\sigma) &= \mathbf{X}_\sigma \boldsymbol{\beta}_\sigma, \\ g_\nu(\nu) &= \mathbf{X}_\nu \boldsymbol{\beta}_\nu, \\ g_\tau(\tau) &= \mathbf{X}_\tau \boldsymbol{\beta}_\tau, \end{aligned}$$

onde:

- $g_\mu(\cdot), g_\sigma(\cdot), g_\nu(\cdot), g_\tau(\cdot)$ são as funções de ligação para os parâmetros μ , σ , ν e τ , respectivamente.
- $\mathbf{X}_\mu, \mathbf{X}_\sigma, \mathbf{X}_\nu, \mathbf{X}_\tau$ representam as matrizes de covariáveis.
- $\boldsymbol{\beta}_\mu, \boldsymbol{\beta}_\sigma, \boldsymbol{\beta}_\nu, \boldsymbol{\beta}_\tau$ são os vetores de coeficientes dos respectivos parâmetros.

2.2 Distribuição Utilizada

A escolha da distribuição será validada utilizando critérios de ajuste como o AIC (Akaike Information Criterion) e gráficos diagnósticos. Por este critério a distribuição escolhida foi a Binomial com zero inflacionado, a que melhor se ajustou aos dados.

2.3 Estimação dos Parâmetros

Os parâmetros do modelo serão estimados pelo método de máxima verossimilhança, maximizando a função de log-verossimilhança:

$$\ell(\mu, \sigma, \nu, \tau) = \sum_{i=1}^n \log f(y_i \mid \mu, \sigma, \nu, \tau),$$

onde $f(y_i \mid \mu, \sigma, \nu, \tau)$ é a função densidade de probabilidade da distribuição assumida para Y .

2.4 Ferramentas Computacionais

A implementação será realizada no software R, utilizando o pacote **gamlss**. Esse pacote permite ajustar modelos GAMLSS, realizar seleções de distribuições e incluir funções suavizadoras para capturar relações não lineares entre as variáveis (AKANTZILIOTOU, 2022).

2.5 Covariáveis Consideradas

- **Idade:** idade do indivíduo.
- **Escolaridade:** nível de instrução do indivíduo.
- **Sexo:** gênero do indivíduo.
- **Cor ou Raça:** autodeclaração de raça/cor.
- **Unidade Federativa (UF):** estado de residência do indivíduo.
- **Tipo de área:** se o indivíduo reside em área urbana ou rural.

Essas variáveis serão analisadas para identificar sua influência nos parâmetros da distribuição, permitindo uma modelagem detalhada e interpretações significativas.

2.6 Critérios de Avaliação do Modelo

O desempenho do modelo será avaliado com base nos seguintes critérios:

- AIC para comparar modelos.

- Gráficos diagnósticos para avaliar a adequação da distribuição.
- Resíduos quantílicos para verificar o ajuste do modelo.

2.7 Análise descritiva

Considerando a capacidade computacional e tempo disponível para realizar esse pré-projeto, foram consideradas apenas informações do último trimestre de 2023, mesmo que seja um período pequeno, é suficiente para exemplificar como a pesquisa seria feita e apresentar resultados parciais. Utilizando o pacote "**PNADcIBGE**" do R foram obtidos os dados com 221158 observações e 225 variáveis. Depois de uma série de análises, as variáveis escolhidas para o modelo foram as citadas anteriormente.

2.7.1 Idade

Tabela 1: Estatísticas descritivas da variável Idade

Medida	Valor
Mínimo	14,00
1º Quartil	29,00
Mediana	40,00
Média	40,18
3º Quartil	50,00
Máximo	108,00

Gráfico 1: Distribuição da Idade da amostra





Gráfico 2: Distribuição da Idade por Situação de Ocupação




Foram consideradas pessoas com pelo menos 14 anos completos, onde a média é aproximadamente 40 anos.

2.7.2 Gênero

Tabela 2: Distribuição de gênero na amostra

Gênero	Quantidade	Percentual (%)
Homem	124738	56,4%
Mulher	96420	43,6%




O desemprego é maior entre as mulheres, mesmo que na amostra hajam mais homens.

2.7.3 Etnia

Tabela 3: Distribuição por etnia

Etnia	Quantidade	Percentual (%)
Branca	89198	40,3%
Preta	24392	11,0%
Amarela	1292	0,58%
Parda	105122	47,5%
Indígena	1123	0,51%
Ignorado	31	0,014%




Aparentemente há uma variação entre as taxas de desemprego de diferentes etnias.

2.7.4 Grau de instrução

Tabela 4: Distribuição por grau de instrução

Grau de Instrução	Quantidade	Percentual (%)
Sem instrução e menos de 1 ano	6513	2,94%
Fundamental incompleto	48672	22,0%
Fundamental completo	16856	7,62%
Médio incompleto	15991	7,23%
Médio completo	76341	34,5%
Superior incompleto	12279	5,55%
Superior completo	44506	20,1%




Há uma variação entre as taxas de desemprego de diferentes escolaridades, indicando que o grau de instrução afeta no desemprego.

2.7.5 Tipo área

Tabela 5: Distribuição por tipo de área

Área	Quantidade	Percentual (%)
Urbana	171851	77,7%
Rural	49307	22,3%



A taxa de desemprego foi maior em habitantes de áreas urbanas no último trimestre de 2023.

2.8 Unidade Federativa

Tabela 6: Distribuição por Unidade da Federação (UF)

UF	Quantidade	Percentual (%)
Rondônia	3318	1,50%
Acre	3317	1,50%
Amazonas	6260	2,83%
Roraima	2644	1,20%
Pará	7992	3,61%
Amapá	2062	0,93%
Tocantins	3569	1,61%
Maranhão	11042	4,99%
Piauí	4257	1,92%
Ceará	8912	4,03%
Rio Grande do Norte	3735	1,69%
Paraíba	5154	2,33%
Pernambuco	7872	3,56%
Alagoas	7369	3,33%
Sergipe	3840	1,74%
Bahia	10012	4,53%
Minas Gerais	17782	8,04%
Espírito Santo	8441	3,82%
Rio de Janeiro	17219	7,79%
São Paulo	20109	9,09%
Paraná	12604	5,70%
Santa Catarina	15661	7,08%
Rio Grande do Sul	13141	5,94%
Mato Grosso do Sul	5232	2,37%
Mato Grosso	6643	3,00%
Goiás	8123	3,67%
Distrito Federal	4848	2,19%

Onde a distribuição de desemprego por UF é dada por:

Tabela 7: Distribuição da taxa de desemprego por Unidade da Federação (UF) no último trimestre de 2023

UF	Total	Desocupados	Taxa de Desemprego (%)
Amapá	2062	272	13.2%
Bahia	10012	1285	12.8%
Pernambuco	7872	897	11.4%
Piauí	4257	463	10.9%
Sergipe	3840	405	10.6%
Rio de Janeiro	17219	1729	10.0%
Distrito Federal	4848	481	9.92%
Paraíba	5154	500	9.7%
Alagoas	7369	691	9.38%
Rio Grande do Norte	3735	322	8.62%
Ceará	8912	757	8.49%
Amazonas	6260	493	7.88%
Pará	7992	622	7.78%
Roraima	2644	181	6.85%
São Paulo	20109	1356	6.74%
Maranhão	11042	726	6.57%
Acre	3317	203	6.12%
Minas Gerais	17782	977	5.49%
Tocantins	3569	190	5.32%
Goiás	8123	431	5.31%
Espírito Santo	8441	424	5.02%
Rio Grande do Sul	13141	622	4.73%
Paraná	12604	567	4.5%
Mato Grosso	6643	255	3.84%
Mato Grosso do Sul	5232	194	3.71%
Rondônia	3318	114	3.44%
Santa Catarina	15661	474	3.03%

Há uma grande variação da taxa do desemprego por unidade federativa, sendo que ela é maior no Amapá e menor em Santa Catarina.

3 Modelo e resultados parciais

Foram testados modelos com as distribuições Binomial, Beta-Binomial e Binomial com zero inflacionado, dessas distribuições a Binomial com zero inflacionado foi a que teve o menor AIC, de 75832.21 enquanto Binomial e Beta-binomial tiveram 82699.09 e 82701.09

respectivamente. Os coeficientes deste modelo foram:

Tabela 8: Tabela de Estimativas do Modelo

Covariável	Estimativa	Erro Padrão	Estat. t	P Valor
Intercepto	-1.3834	0.1312	-10.545	< 2e-16
Idade	-0.0467	0.0008	-59.581	< 2e-16
Fund. incompleto	0.0240	0.0660	0.363	0.7165
Fund. completo	-0.0214	0.0716	-0.298	0.7656
Médio incompleto	0.0243	0.0706	0.344	0.7309
Médio completo	-0.2848	0.0656	-4.341	1.42e-05
Sup. incompleto	-0.5423	0.0753	-7.204	5.85e-13
Sup. completo	-0.8658	0.0695	-12.452	< 2e-16
Cor preta	0.1858	0.0324	5.733	9.88e-09
Cor amarela	0.1132	0.1279	0.885	0.3762
Cor parda	0.1426	0.0232	6.154	7.56e-10
Cor indígena	-0.1575	0.1428	-1.103	0.2701
Cor ignorada	0.1140	0.7668	0.149	0.8818
Zona rural	-0.4927	0.0263	-18.721	< 2e-16

Tabela 9: Continuação Tabela de Estimativas do Modelo

Covariável	Estimativa	Erro Padrão	Estat. t	P Valor
UF's				
Acre	0.5743	0.1365	4.206	2.60e-05
Amazonas	0.8224	0.1208	6.808	9.95e-12
Roraima	0.6417	0.1401	4.582	4.61e-06
Pará	0.7666	0.1189	6.450	1.12e-10
Amapá	1.3957	0.1326	10.528	< 2e-16
Tocantins	0.4275	0.1375	3.108	0.0019
Maranhão	0.6732	0.1171	5.749	8.98e-09
Piauí	1.2847	0.1221	10.517	< 2e-16
Ceará	0.9292	0.1170	7.942	2.00e-15
Rio Grande do Norte	1.0212	0.1268	8.055	8.01e-16
Paraíba	1.1044	0.1214	9.094	< 2e-16
Pernambuco	1.3051	0.1160	11.247	< 2e-16
Alagoas	1.0747	0.1174	9.156	< 2e-16
Sergipe	1.1874	0.1239	9.581	< 2e-16
Bahia	1.4079	0.1142	12.324	< 2e-16
Minas Gerais	0.4775	0.1151	4.149	3.35e-05
Espírito Santo	0.3887	0.1230	3.159	0.0016
Rio de Janeiro	1.2455	0.1126	11.060	< 2e-16
São Paulo	0.8057	0.1134	7.107	1.19e-12
Paraná	0.3174	0.1195	2.656	0.0079
Santa Catarina	-0.0976	0.1214	-0.805	0.4211
Rio Grande do Sul	0.4448	0.1192	3.732	0.0002
Mato Grosso do Sul	0.1570	0.1356	1.157	0.2471
Mato Grosso	0.0544	0.1302	0.418	0.6762
Goiás	0.4069	0.1225	3.322	0.0009
Distrito Federal	1.2709	0.1217	10.441	< 2e-16

Onde as categorias de referência são "sem instrução de ensino", "cor branca", "urbana" e "Rondônia", para as variáveis grau de instrução, cor/raça, tipo de área e UF's respectivamente. Todas as variáveis são significativas para o modelo, ou seja, são relevantes. Coeficientes negativos indicam que a covariável diminui a taxa de desemprego, enquanto positivo significa que aumenta.

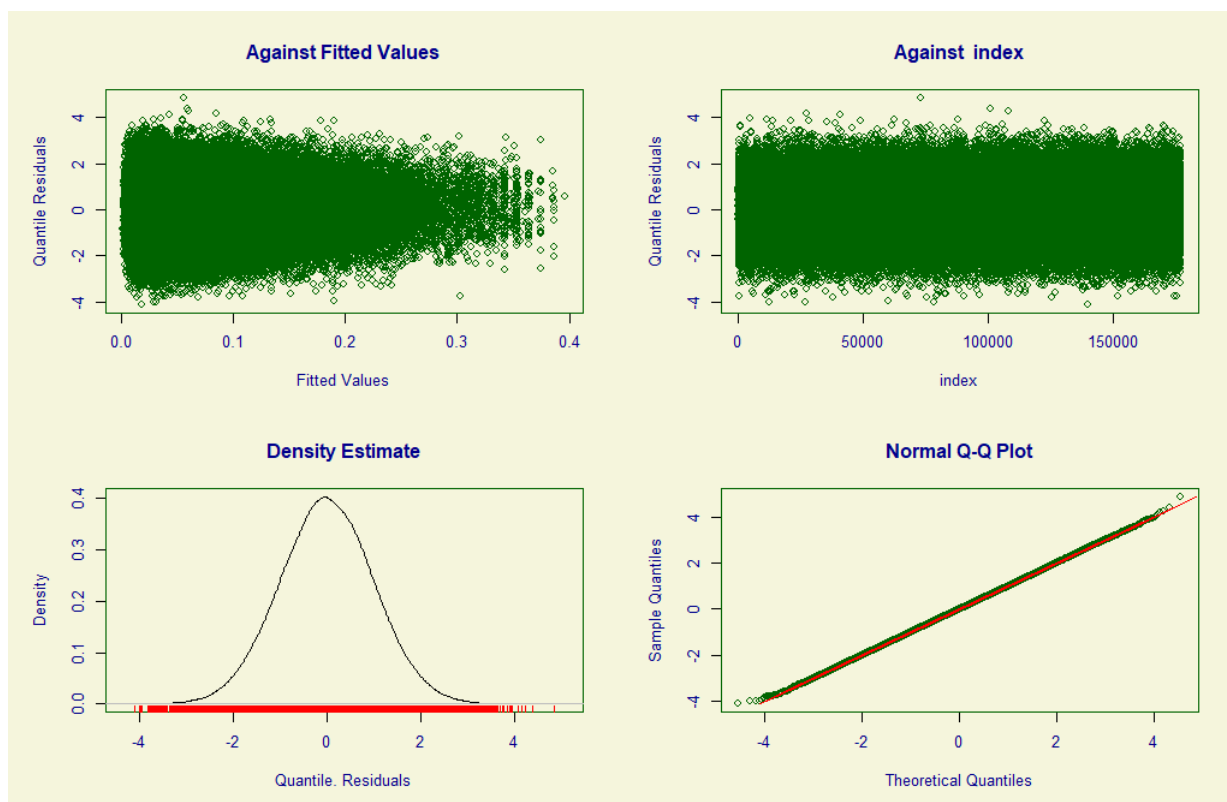



Gráfico 7: Curva ROC do Modelo GAMLSS



Pelo diagnóstico e análise dos resíduos quantílicos o modelo está adequado, sem nenhuma indicação de que há afastamentos das suposições iniciais. Utilizando a curva ROC (Receiver Operating Characteristic) para avaliar o desempenho do modelo, temos que a área a baixo da curva é de 0.7082, considerado aceitável, com uma capacidade preditiva considerável.

Referências

- AKANTZILIOTOU, D. M. S. R. A. R. . C. *gamlss: Generalized Additive Models for Location Scale and Shape*. [S.l.: s.n.], 2022.
- BASTIANI, M. D. S. R. A. R. G. Z. H. V. V. F. D. *Flexible Regression and Smoothing: Using GAMLSS in R*. CRC Press. [S.l.]: Chapman and Hall/CRC, 2017.
- BOURGUIGNON, A. B. A. . F. *Handbook of Income Distribution*. [S.l.]: Elsevier, 2000.
- CRIBARI-NETO, S. L. F. F. Beta regression for modelling rates and proportions. *Journal of Applied Statistics*, 2004.
- HOFFMANN, R. *Análise de Dados Socioeconômicos*. [S.l.]: Editora Saraiva, 2016.
- MILANOVIC, B. *Global Inequality: A New Approach for the Age of Globalization*. [S.l.]: Harvard University Press, 2016.
- SILVA, P. I. da. Aplicação de modelos aditivos generalizados para locação, escala e forma (gamlss) no estudo da convergência de renda. *Programa de Pós-Graduação em Economia*, 2013.
- STASINOPOULOS, R. . Generalized additive models for location, scale and shape. *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, v. 54(3), p. 507–554, 2005.
- STASINOPOULOS, R. . Modeling income distributions using gamlss. *Economics Bulletin*, v. 37(2), p. 1104–1112, 2017.

Código utilizado:

```
# Carregar pacotes
library(PNADcIBGE)
library(tidyverse)
library(ggplot2)
library(gamlss)
library(caret)
library(pROC)

# Obter dados
dados_pnad <- get_pnad(year = 2023, quarter = 4,
                      vars = c("VD4002", "V2009", "VD3004",
                              "V2007", "V2010", "UF",
                              "V1022", "VD4001"), design = FALSE)

summary(dados_pnad)
glimpse(dados_pnad)

dados_pnad$VD4002_num <- recode(dados_pnad$VD4002,
                              "Pessoas ocupadas" = 1,
                              "Pessoas desocupadas" = 2)

table(dados_pnad$VD4002_num)
dados_pnad_filtrados <- dados_pnad %>%
  filter(!is.na(VD4002_num) & VD4002_num %in% c(1, 2))

# Calcular a taxa de desemprego
taxa_desemprego <- dados_pnad_filtrados %>%
  summarise(
    desocupados = sum(VD4002_num == 2, na.rm = TRUE),
    forca_trabalho = sum(VD4002_num %in% c(1, 2), na.rm = TRUE),
    taxa_desemprego = (desocupados / forca_trabalho) * 100
  )
taxa_desemprego

#Resumo das variáveis numéricas (idade)
dados_pnad_filtrados %>%
  select(V2009) %>%
  summary()
```

```
#Resumo das variáveis características
# Distribuição por sexo
dados_pnad_filtrados %>%
  count(V2007) %>%
  mutate(perc = n / sum(n) * 100)

# Distribuição por escolaridade
dados_pnad_filtrados %>%
  count(VD3004) %>%
  mutate(perc = n / sum(n) * 100)

# Distribuição por raça/cor
dados_pnad_filtrados %>%
  count(V2010) %>%
  mutate(perc = n / sum(n) * 100)

# Distribuição por região (UF)
table <- dados_pnad_filtrados %>%
  count(UF) %>%
  mutate(perc = n / sum(n) * 100)

# Distribuição por área urbana/rural
dados_pnad_filtrados %>%
  count(V1022) %>%
  mutate(perc = n / sum(n) * 100)

#Gráficos
ggplot(dados_pnad_filtrados, aes(x = V2009)) +
  geom_histogram(binwidth = 5, fill = "blue", alpha = 0.6, color = "black") +
  labs(title = "Gráfico 1: Distribuição da Idade da amostra",
        x = "Idade",
        y = "Frequência") +
  theme_minimal()

dados_pnad_filtrados %>%
  group_by(V2007) %>%
  summarise(taxa_desemprego = sum(VD4002_num == 2, na.rm = TRUE) / sum(VD4002_num %
    na.rm = TRUE) * 100) %>%
  ggplot(aes(x = factor(V2007, labels = c("Masculino", "Feminino"))),
```

```

    y = taxa_desemprego,
    fill = factor(V2007))) +
geom_bar(stat = "identity") +
labs(title = "Gráfico 3: Taxa de Desemprego por Sexo",
      x = "Sexo",
      y = "Taxa de Desemprego (%)") +
theme_minimal()

```

```

dados_pnad_filtrados %>%
  group_by(V2010) %>%
  summarise(taxa_desemprego = sum(VD4002_num == 2, na.rm = TRUE) / sum(VD4002_num %in% c(1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28, 29, 30, 31, 32, 33, 34, 35, 36, 37, 38, 39, 40, 41, 42, 43, 44, 45, 46, 47, 48, 49, 50, 51, 52, 53, 54, 55, 56, 57, 58, 59, 60, 61, 62, 63, 64, 65, 66, 67, 68, 69, 70, 71, 72, 73, 74, 75, 76, 77, 78, 79, 80, 81, 82, 83, 84, 85, 86, 87, 88, 89, 90, 91, 92, 93, 94, 95, 96, 97, 98, 99, 100), na.rm = TRUE) * 100) %>%
  ggplot(aes(x = factor(V2010, labels = c("Branca", "Preta", "Amarela",
                                          "Parda", "Indígena", "Ignorado")),
            y = taxa_desemprego,
            fill = factor(V2010))) +
  geom_bar(stat = "identity") +
  labs(title = "Gráfico 4: Taxa de Desemprego por Etnia",
        x = "Etnia",
        y = "Taxa de Desemprego (%)") +
  theme_minimal()

```

```

dados_pnad_filtrados %>%
  group_by(VD3004) %>%
  summarise(taxa_desemprego = sum(VD4002_num == 2, na.rm = TRUE) / sum(VD4002_num %in% c(1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28, 29, 30, 31, 32, 33, 34, 35, 36, 37, 38, 39, 40, 41, 42, 43, 44, 45, 46, 47, 48, 49, 50, 51, 52, 53, 54, 55, 56, 57, 58, 59, 60, 61, 62, 63, 64, 65, 66, 67, 68, 69, 70, 71, 72, 73, 74, 75, 76, 77, 78, 79, 80, 81, 82, 83, 84, 85, 86, 87, 88, 89, 90, 91, 92, 93, 94, 95, 96, 97, 98, 99, 100), na.rm = TRUE) * 100) %>%
  ggplot(aes(x = factor(VD3004), y = taxa_desemprego)) +
  geom_bar(stat = "identity", fill = "purple", alpha = 0.7) +
  labs(title = "Gráfico 5: Taxa de Desemprego por Escolaridade",
        x = "Escolaridade",
        y = "Taxa de Desemprego (%)") +
  theme_minimal() +
  coord_flip()

```

```

ggplot(dados_pnad_filtrados, aes(x = factor(VD4002_num, labels = c("Ocupado", "Desocupado", "Inativo")),
                                y = V2009)) +
  geom_boxplot(fill = "orange", alpha = 0.6) +
  labs(title = "Gráfico 2: Distribuição da Idade por Situação de Ocupação",
        x = "Situação de Ocupação",

```



```

      y = "Idade") +
    theme_minimal()

dados_pnad_filtrados %>%
  group_by(V1022) %>%
  summarise(taxa_desemprego = sum(VD4002_num == 2, na.rm = TRUE) / sum(VD4002_num %
                                                                    na.rm = TRUE) * 100) %>%
  ggplot(aes(x = factor(V1022, labels = c("Urbana", "Rural")),
            y = taxa_desemprego,
            fill = factor(V1022))) +
  geom_bar(stat = "identity") +
  labs(title = "Gráfico 6: Taxa de Desemprego por área",
       x = "Área",
       y = "Taxa de Desemprego (%)") +
  theme_minimal()

tabela_desemprego_uf <- dados_pnad %>%
  filter(!is.na(VD4002_num)) %>%
  group_by(UF) %>%
  summarise(
    Total = n(),
    Desempregados = sum(VD4002_num == 2),
    Taxa_Desemprego = round((Desempregados / Total) * 100, 2)
  ) %>%
  arrange(desc(Taxa_Desemprego))
print(tabela_desemprego_uf, n=27)

# Modelagem
trainIndex <- createDataPartition(dados_pnad_filtrados$VD4002_num, p = 0.8,
                                   list = FALSE)

dados_treino <- dados_pnad_filtrados[trainIndex, ]
dados_teste <- dados_pnad_filtrados[-trainIndex, ]

### Ajuste do modelos GAMLSS
####Binomial
modelo_gamlss_BI <- gamlss(VD4002 ~ V2009 + VD3004 + V2010 + V1022 + UF,
                          family = BI, data = dados_treino)
summary(modelo_gamlss_BI)

```

```
####Beta-binomial
modelo_gamlss_BB <- gamlss(VD4002 ~ V2009 + VD3004 + V2010 + V1022 + UF,
                           family = BB, data = dados_treino)
summary(modelo_gamlss_BB)

####Zero inflacionada
modelo_gamlss_ZIBI <- gamlss(VD4002 ~ V2009 + VD3004 + V2010 + V1022 + UF,
                             family = ZIBI, data = dados_treino)
summary(modelo_gamlss_ZIBI)

AIC(modelo_gamlss_BI, modelo_gamlss_BB, modelo_gamlss_ZIBI)

modelo_gamlss <- gamlss(VD4002 ~ V2009 + VD3004 + V2010 + V1022 + UF,
                       family = ZIBI, data = dados_treino)

#### Resumo do modelo
summary(modelo_gamlss)
plot(modelo_gamlss)
### Prever a probabilidade de desemprego no conjunto de teste

predicoes <- predict(modelo_gamlss, newdata = dados_teste, type = "response")
plot(predicoes)
### Converter para classe (1: Ocupado, 2: Desempregado)
dados_teste$predito <- ifelse(predicoes > 0.5, 2, 1)

### Criar matriz de confusão
confusionMatrix(as.factor(dados_teste$predito), as.factor(dados_teste$VD4002))
roc_obj <- roc(dados_teste$VD4002, predicoes)

###AUC e roc
auc(roc_obj)
plot(roc_obj, main = "Gráfico 7: Curva ROC do Modelo GAMLSS")
```